

LİTERATÜR TARAMASI RAPORU

Proje Başlığı: Yapay Sinir Ağları Kullanılarak Hava Kirliliği (PM2.5) Konsantrasyonunun Zaman Serisi Analizi ve Tahmini **Ders:** Uygulamalı Sinir Ağları **Konu:** Regresyon Temelli Hava Kalitesi Modellemesi

1. GİRİŞ

Hava kirliliği, özellikle 2.5 mikrometreden küçük ince partikül maddeler (PM2.5), insan sağlığı ve ekosistemler üzerinde ciddi tehditler oluşturan küresel bir sorundur. PM2.5, akciğerlerin derinliklerine nüfuz edebilme özelliği nedeniyle solunum yolu hastalıkları, kardiyovasküler sorunlar ve erken ölümlerle doğrudan ilişkilendirilmiştir. Bu nedenle, PM2.5 seviyelerinin doğru tahmini, erken uyarı sistemlerinin geliştirilmesi ve kamu sağlığının korunması açısından kritik öneme sahiptir.

Geleneksel olarak hava kalitesi tahmini, kimyasal taşıma modelleri (CTM) gibi deterministik yöntemlere dayanmaktaydı; ancak bu modeller yüksek hesaplama maliyeti ve karmaşık teorik varsayımlar gerektirmektedir. Günümüzde, veri odaklı yaklaşımlar olan **Yapay Sinir Ağları (YSA)**, doğrusal olmayan karmaşık ilişkileri modelleme yetenekleri sayesinde PM2.5 tahmininde öne çıkmaktadır.

2. PROBLEMİN TANIMI: BİR REGRESYON VE ZAMAN SERİSİ PROBLEMİ

Bu proje, PM2.5 konsantrasyonunu tahmin etmeyi hedefleyen bir **regresyon** problemidir. Sınıflandırma projelerinden farklı olarak burada amaç, sürekli bir sayısal değeri (konsantrasyon miktarı) en az hata ile tahmin etmektir.

Hava kirliliği verileri doğası gereği bir **zaman serisidir**; yani geçmişteki değerler ve meteorolojik değişkenler (sıcaklık, nem, rüzgar hızı vb.), gelecekteki hava kalitesi seviyelerini belirleyen temel unsurlardır. Literatür, PM2.5 dinamiklerinin sadece yerel emisyonlara değil, aynı zamanda atmosferik stabilite ve meteorolojik koşullara da sıkı sıkıya bağlı olduğunu göstermektedir.

3. TEORİK ARKAPLAN VE MODEL MİMARİLERİ

3.1. Çok Katmanlı Perseptron (MLP)

Projenin temelini oluşturan **Çok Katmanlı Perseptron (MLP)**, ileri beslemeli bir sinir ağı mimarisidir. Literatürde, MLP modellerinin meteorolojik parametreler ve kirlilik seviyeleri arasındaki doğrusal olmayan haritalamayı yakalamada oldukça başarılı olduğu kanıtlanmıştır.

- Mimari Yapı:** Standart bir MLP; giriş katmanı, bir veya daha fazla gizli katman ve bir çıkış katmanından oluşur. Gizli katmanlarda genellikle *tangent sigmoid* veya

ReLU gibi aktivasyon fonksiyonları kullanılırken, regresyon görevleri için çıkış katmanında doğrusal (linear) bir fonksiyon tercih edilir.

- **Öğrenme ve Kayıp Fonksiyonu:** MLP, hata geri yayılım (backpropagation) algoritması ile eğitilir. Regresyon problemlerinde modelin başarısı, tahmin edilen değer ile gerçek değer arasındaki farkı ölçen **Ortalama Kare Hata (Mean Squared Error - MSE)** veya bunun karekökü olan **RMSE** fonksiyonları ile minimize edilir.

3.2. Modern Derin Öğrenme Yaklaşımları

Literatür taraması, MLP'nin yanı sıra daha karmaşık mimarilerin de kullanıldığını göstermektedir:

- **CNN (Evrişimli Sinir Ağları):** Verilerdeki yerel desenleri ve mekansal özellikleri çıkarmada etkilidir.
- **LSTM ve GRU:** Uzun vadeli zaman bağımlılıklarını modellemek için tasarlanmış tekrarlayan sinir ağı (RNN) türleridir.
- **Transformer ve Dikkat Mekanizmaları:** Paralel işlem yapabilme ve veriler arasındaki uzak ilişkileri (self-attention) kurabilme yeteneği ile son yıllarda en yüksek başarı oranlarına ulaşan mimarilerdir.

4. VERİ SETİ VE DEĞİŞKEN SEÇİMİ

4.1. Girdi Değişkenleri (Özellikler)

Başarılı bir PM2.5 tahmini için literatürde kullanılan temel girdi değişkenleri şunlardır:

1. **Gecikmeli PM2.5 Değerleri:** Önceki gün veya saatlerin konsantrasyon seviyeleri.
2. **Meteorolojik Parametreler:** Sıcaklık, bağıl nem, rüzgar hızı, rüzgar yönü, hava basıncı ve yağış miktarı. Özellikle sıcaklığın PM2.5 üzerinde güçlü bir causal (nedensel) etkisi olduğu belirtilmiştir.
3. **Zamansal Göstergeler:** Haftanın günü ve yılın ayı gibi döngüsel veriler, trafik ve ısınma kalıplarını anlamada yardımcı olur.

4.2. Veri Ön İşleme

Tahmin performansını artırmak için verilerin normalize edilmesi (Min-Max Scaling) veya standartlaştırılması (Z-score) şarttır. Ayrıca, eksik verilerin doğrusal interpolasyon veya önceki haftanın verileriyle doldurulması veri bütünlüğünü sağlar.

5. BULGULAR VE MODEL ANALİZİ

5.1. Performans Metrikleri

Modellerin başarısı genellikle şu metriklerle değerlendirilir:

- **R-Kare (R^2):** Verideki varyansın ne kadarının açıklandığını gösterir (1'e yakın olması istenir).
- **RMSE ve MAE:** Tahmin hatalarının büyüklüğünü ölçer.

5.2. Literatürdeki Karşılaştırmalı Sonuçlar

- Zoqi vd. (2025), üç farklı istasyonda MLP kullanarak R^2 değerlerini 0.65 ile 0.79 arasında raporlamıştır.
- Bai vd. (2024), CNN-LSTM hibrit modelinin tekil CNN veya LSTM modellerinden daha yüksek doğruluk ($R^2=0.91$) sunduğunu göstermiştir.
- Zeng vd. (2026) ise **Transformer-LSTM** yapısının, uzun vadeli tahminlerde diğer tüm modelleri geride bıraktığını belirtmiştir.
- Booth vd. (2025), meteorolojik verilerin (özellikle rüzgar ve sıcaklık) tüm bölgelerde tahmin başarısını tutarlı bir şekilde artırdığını doğrulamıştır.

6. SONUÇ VE ÖNERİLER

Yapılan literatür taraması sonucunda, PM2.5 tahmininin doğrusal olmayan karmaşık bir regresyon problemi olduğu ve Yapay Sinir Ağları'nın bu süreçte en güçlü araçlardan biri olduğu görülmüştür.

Ders projeniz için **MLP mimarisi**, temel bir regresyon modeli olarak sağlam bir başlangıç noktası sunmaktadır. **MSE kayıp fonksiyonu** kullanımı, büyük hataları daha fazla cezalandırarak modelin hassasiyetini artıracaktır. Projenizde sadece geçmiş kirlilik verilerini değil, aynı zamanda sıcaklık ve rüzgar hızı gibi meteorolojik değişkenleri de modele dahil etmeniz, literatürdeki bulgularla uyumlu olarak tahmin doğruluğunu anlamlı derecede yükseltecektir.

KAYNAKÇA

Bu rapor, dosya havuzunda yer alan Zoqi vd. (2025), Bai vd. (2024), Wu vd. (2025), Booth vd. (2025) ve Zeng vd. (2026) çalışmalarından derlenmiştir.